

Теорема

Определение. Назовем *обобщенно-линейной моделью с натуральной функцией связи* и априорным распределением на вектор параметров $p(\mathbf{w}|\mathbf{A})$ вероятностную модель, совместное правдоподобие которой имеет вид

$$p(y, \mathbf{w}|\mathbf{X}, \mathbf{A}) = p(y|\mathbf{X}, \mathbf{w})p(\mathbf{w}|\mathbf{A}), \text{ где } p(y|\mathbf{X}, \mathbf{w}) = \prod_{i=1}^m p(y_i|\mathbf{x}_i, \mathbf{w})$$

$$p(y_i|\mathbf{x}_i, \mathbf{w}) = c(y_i) \exp(\theta_i y_i - b(\theta_i)), \text{ где } \theta_i = \mathbf{w}^T \mathbf{x}_i$$

Замечание. Отметим, что логистическая модель является обобщенно-линейной моделью с натуральной функцией связи для бинарной целевой переменной $y_i \in \{-1, 1\}$, так как

$$p(y_i|\mathbf{x}_i, \mathbf{w}) = \sigma(y_i \mathbf{x}_i^T \mathbf{w}) = \frac{\exp(y_i \mathbf{x}_i^T \mathbf{w})}{\exp(\mathbf{w}^T \mathbf{x}_i) + \exp(-\mathbf{w}^T \mathbf{x}_i)}.$$

Тогда, взяв $(y_i) = 1, b(\theta_i) = \exp(\theta_i) + \exp(-\theta_i)$, получим требуемое.

Введем матрицу вторых производных $\mathbf{H}_m(\mathbf{w})$:

$$\mathbf{H}_m(\mathbf{w}) = \sum_{i=1}^m \mathbf{x}_i \frac{\partial^2 b}{\partial \theta^2}(\mathbf{w}^T \mathbf{x}_i) \mathbf{x}_i^T.$$

$\tilde{\mathbf{H}}(\tilde{\mathbf{v}}) = \mathbf{H}(\tilde{\mathbf{v}}) + \mathbf{A}$, где \mathbf{A} - матрица корреляции для априорного распределения весов.

Теорема 14 (Адуенко (2016)). Пусть имеется обобщенно-линейная модель с натуральной функцией связи с истинным вектором параметров \mathbf{w} и нормальным априорным распределением на вектор параметров $\mathbf{w} \sim \mathcal{N}(\mathbf{w}|\mathbf{0}, \mathbf{A}_m^{-1})$, причем $\exists c_0 < \infty : \|\mathbf{A}_m\| < c_0 \ \forall m$. Пусть также $\sum_{i=1}^m \mathbf{x}_i \mathbf{x}_i^T$ имеет полный ранг для $m \geq m_0$, $\lambda_{\min}(\mathbf{H}(\mathbf{w})) \rightarrow \infty$ при $m \rightarrow \infty$ и

$$\forall \delta > 0 \max_{\mathbf{v} \in O_m^\delta(\mathbf{w})} \|\mathbf{H}(\mathbf{w})^{-1/2} \mathbf{H}(\mathbf{v}) \mathbf{H}(\mathbf{w})^{-T/2} - \mathbf{I}\| \rightarrow 0 \text{ при } m \rightarrow \infty.$$

Тогда $\tilde{\mathbf{H}}(\hat{\mathbf{w}})^{1/2}(\hat{\mathbf{w}} - \mathbf{w}) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{I}_n)$, где $\hat{\mathbf{w}} = \arg \max_{\mathbf{v}} p(y, \mathbf{v}|\mathbf{X}, \mathbf{A})$ есть оценка максимума апостериорной вероятности для вектора параметров модели, а $\mathbf{H}(\hat{\mathbf{w}})^{1/2}$ есть корень из матрицы в терминах разложения Холецкого [3].

Теорема 15 (Адуенко (2016)). Пусть имеется две обобщенно-линейные модели с натуральной функцией связи с одинаковым истинным вектором параметров \mathbf{w} и нормальным априорным распределением на вектор параметров $\mathbf{w} \sim \mathcal{N}(\mathbf{w}|\mathbf{0}, \mathbf{A}_{m^k}^{-1})$, $k = 1, 2$, причем $\exists c_0^k < \infty : \|\mathbf{A}_{m^k}^k\| < c_0^k \ \forall m^k$, $k = 1, 2$. Пусть также значение вектора параметров \mathbf{w} для второй модели известно точно. Пусть для первой модели выполнено, что $\sum_{i=1}^{m^1} \mathbf{x}_i \mathbf{x}_i^\top$ имеет полный ранг для $m^1 \geq m_0$, $\lambda_{\min}(\mathbf{H}_{m^1}(\mathbf{w})) \rightarrow \infty$ при $m^1 \rightarrow \infty$ и

$$\forall \delta > 0 \quad \max_{\mathbf{v} \in O_{m^1}^\delta(\mathbf{w})} \|\mathbf{H}_{m^1}(\mathbf{w})^{-1/2} \mathbf{H}_{m^1}(\mathbf{v}) \mathbf{H}_{m^1}(\mathbf{w})^{-T/2} - \mathbf{I}\| \rightarrow 0 \text{ при } m^1 \rightarrow \infty.$$

Тогда $-2 \log s\text{-score} = (\hat{\mathbf{w}} - \mathbf{w})^\top \tilde{\mathbf{H}}_{m^1}(\hat{\mathbf{w}})(\hat{\mathbf{w}} - \mathbf{w}) \xrightarrow{d} \chi^2(n)$, где $\hat{\mathbf{w}}$ есть оценка максимума апостериорной вероятности для вектора параметров модели (см. (3.1) для $\mathbf{A} = \mathbf{A}_{m^1}^1$), $\tilde{\mathbf{H}}_{m^1}(\hat{\mathbf{w}})^{1/2}$ есть корень из матрицы в терминах разложения Холецкого [3], а m^1 — число объектов в выборке для первой модели.

1 Теорема

(Адуенко (2016)). Пусть имеется две обобщенно-линейные модели с натуральной функцией связи с одинаковым истинным вектором параметров \mathbf{w} и нормальным априорным распределением на вектор параметров $\mathbf{w} \sim \mathcal{N}(\mathbf{w}|\mathbf{0}, \mathbf{A}_{m^k}^{-1})$, $k = 1, 2$, причем $\exists c_0^k < \infty : \|\mathbf{A}_{m^k}^k\| < c_0^k \ \forall m^k, k = 1, 2$. Пусть для обеих моделей выполнено, что $\sum_{i=1}^{m^k} \mathbf{x}_i \mathbf{x}_i^\top$ имеет полный ранг для $m^k \geq m_0^k, k = 1, 2$, $\lambda_{\min}(\mathbf{H}_{m^k}(\mathbf{w})) \rightarrow \infty$ при $m^k \rightarrow \infty, k = 1, 2$ и

$$\forall \delta > 0 \quad \max_{\mathbf{v} \in O_{m^k}^\delta(\mathbf{w})} \|\mathbf{H}_{m^k}(w)^{-1/2} \mathbf{H}_{m^k}(v) \mathbf{H}_{m^k}(w)^{-T/2} - \mathbf{I}\| \rightarrow 0 \text{ при } m^k \rightarrow \infty, k = 1, 2.$$

Пусть также

$$\|\tilde{\mathbf{H}}_{m^1}(\hat{\mathbf{w}}_1)\| \|\tilde{\mathbf{H}}_{m^2}^{-1}(\hat{\mathbf{w}}_2)\| \rightarrow 0 \text{ при } m = \min(m^1, m^2) \rightarrow \infty.$$

Тогда $-2 \log s\text{-score} = (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1)^\top (\tilde{\mathbf{H}}_{m^1}^{-1}(\hat{\mathbf{w}}_1) + \tilde{\mathbf{H}}_{m^2}^{-1}(\hat{\mathbf{w}}_2))^{-1} (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1) \xrightarrow{d} \chi^2(n)$, где $\hat{\mathbf{w}}_k, k = 1, 2$ есть оценки максимума апостериорной вероятности для вектора параметров модели $k = 1, 2$, $\tilde{\mathbf{H}}_{m^k}(\hat{\mathbf{w}}_k)^{1/2}$ есть корень из матрицы в терминах разложения Холецкого, а m^k число объектов в выборке для модели $k = 1, 2$.

Доказательство. Обозначим $\tilde{\mathbf{H}}_1 = \tilde{\mathbf{H}}_{m^1}(\hat{\mathbf{w}}_1)$, $\tilde{\mathbf{H}}_2 = \tilde{\mathbf{H}}_{m^2}(\hat{\mathbf{w}}_2)$. Зафиксируем произвольные $1 > \eta > 0$ и $1 > \varepsilon n > 0$. Из условия теоремы имеем, что

$$\exists m' : \forall m \geq m' \ \mathbb{P}(\|\tilde{\mathbf{H}}_1\| \|\tilde{\mathbf{H}}_2\| \leq \varepsilon) \geq 1 - \eta.$$

Тогда с учетом $\varepsilon < 1$ с вероятностью $\geq 1 - \eta$ имеем

$$-2 \log s\text{-score} = (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1)^\top \tilde{\mathbf{H}}_1(\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1) + (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1)^\top \tilde{\mathbf{H}}_1 \sum_{l=1}^{\infty} (-1)^l (\tilde{\mathbf{H}}_2^{-1} \tilde{\mathbf{H}}_1)^l (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1).$$

С учетом

$$\begin{aligned}
 & \left| (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1)^T \tilde{\mathbf{H}}_1 \sum_{l=1}^{\infty} (-1)^l (\tilde{\mathbf{H}}_2^{-1} \tilde{\mathbf{H}}_1)^l (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1) \right| \leq \\
 & \sum_{l=1}^{\infty} (-1)^l (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1)^T \tilde{\mathbf{H}}_1 (\tilde{\mathbf{H}}_2^{-1} \tilde{\mathbf{H}}_1)^l (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1) = \\
 & \sum_{l=1}^{\infty} (-1)^l \text{tr} \left((\tilde{\mathbf{H}}_2^{-1} \tilde{\mathbf{H}}_1)^l (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1) (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1)^T \tilde{\mathbf{H}}_1 \right) \leq \\
 & \sum_{l=1}^{\infty} (-1)^l \text{tr} \left((\tilde{\mathbf{H}}_2^{-1} \tilde{\mathbf{H}}_1)^l \right) (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1)^T \tilde{\mathbf{H}}_1 (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1) \leq \sum_{l=1}^{\infty} (-1)^l (n\varepsilon)^l (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1)^T \tilde{\mathbf{H}}_1 (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1) = \\
 & \frac{n\varepsilon}{1-n\varepsilon} (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1)^T \tilde{\mathbf{H}}_1 (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1).
 \end{aligned}$$

Получаем, что

$$\mathbb{P} \left(\left| -2 \log s - \text{score} / (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1)^T \tilde{\mathbf{H}}_1 (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1) - 1 \right| \leq \frac{n\varepsilon}{1-n\varepsilon} \right) \geq 1 - \eta,$$

откуда в силу произвольности ε и η получим

$$-2 \log s - \text{score} / (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1)^T \tilde{\mathbf{H}}_1 (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1) \xrightarrow{\mathbb{P}} 1. \quad (1)$$

$$(\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1)^T \tilde{\mathbf{H}}_1 (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1) = (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}})^T \tilde{\mathbf{H}}_1 (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}) + (\hat{\mathbf{w}}_1 - \hat{\mathbf{w}})^T \tilde{\mathbf{H}}_1 (\hat{\mathbf{w}}_1 - \hat{\mathbf{w}}) + 2(\hat{\mathbf{w}}_2 - \hat{\mathbf{w}})^T \tilde{\mathbf{H}}_1 (\hat{\mathbf{w}}_1 - \hat{\mathbf{w}}) \quad (2)$$

В условиях теоремы из теоремы 15 получаем, что

$$(\hat{\mathbf{w}}_k - \hat{\mathbf{w}})^T \tilde{\mathbf{H}}_k (\hat{\mathbf{w}}_k - \hat{\mathbf{w}}) \xrightarrow{d} \chi^2(n) \text{ при } m \rightarrow \infty, \quad k = 1, 2 \quad (3)$$

Покажем, что

$$\|\tilde{\mathbf{H}}_1\| \|\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}\|^2 \xrightarrow{\mathbb{P}} 0, \quad (4)$$

Из (3) заключаем, что

$$\forall \varepsilon > 0 \exists m_\varepsilon, \exists c_\varepsilon : \forall m^k \geq m_\varepsilon \mathbb{P}((\hat{\mathbf{w}}_k - \hat{\mathbf{w}})^T \tilde{\mathbf{H}}_k (\hat{\mathbf{w}}_k - \hat{\mathbf{w}}) > c_\varepsilon) < \varepsilon.$$

Тогда для модели $k = 2$ получаем с учетом

$$(\hat{\mathbf{w}}_2 - \hat{\mathbf{w}})^T \tilde{\mathbf{H}}_2 (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}) \geq \lambda_{\min}(\tilde{\mathbf{H}}_2) \|\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}\|^2$$

$$\forall \varepsilon > 0 \exists m_\varepsilon, \exists c_\varepsilon : \forall m^k \geq m_\varepsilon \mathbb{P}(\lambda_{\min}(\tilde{\mathbf{H}}_2) \|\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}\|^2 > c_\varepsilon) < \varepsilon.$$

В условиях теоремы из сходимости

$$\|\tilde{\mathbf{H}}_1\| \|\tilde{\mathbf{H}}_2^{-1}\| \xrightarrow{\mathbb{P}} 0 \text{ при } m \rightarrow 0$$

получаем, что для любого фиксированного c_ε

$$\forall \eta > 0 \forall \delta \exists m_\delta : \forall m \geq m_\delta \mathbb{P} \left(\frac{\lambda_{\max}(\tilde{\mathbf{H}}_1)}{\lambda_{\min}(\tilde{\mathbf{H}}_2)} < \frac{\delta}{c_\varepsilon} \right) > 1 - \eta.$$

Тогда получаем, что

$$\forall \varepsilon > 0 \forall \eta > 0 \forall \delta > 0 \exists m'' = \max(m_\varepsilon, m_\delta) : \forall m \geq m'' \mathbb{P}(\|\tilde{\mathbf{H}}_1\| \|\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}\|^2 < \delta) > 1 - \varepsilon - \eta.$$

что как раз и означает требуемое (4). Покажем теперь, что

$$(\hat{\mathbf{w}}_2 - \hat{\mathbf{w}})^T \tilde{\mathbf{H}}_1 (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}) \xrightarrow{\mathbb{P}} 0 \text{ при } m \rightarrow \infty \quad (5)$$

$$(\hat{\mathbf{w}}_1 - \hat{\mathbf{w}})^T \tilde{\mathbf{H}}_1 (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}) \xrightarrow{\mathbb{P}} 0 \text{ при } m \rightarrow \infty \quad (6)$$

Отметим, что (5) непосредственно следует из (4), так как

$$\hat{\mathbf{w}}_2 - \hat{\mathbf{w}})^T \tilde{\mathbf{H}}_1 (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}) \leq \|\tilde{\mathbf{H}}_1\| \|\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}\|^2.$$

Для доказательства (6) заметим, что

$$(\hat{\mathbf{w}}_1 - \hat{\mathbf{w}})^T \tilde{\mathbf{H}}_1 (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}) = (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}})^T \tilde{\mathbf{H}}_1^{1/2} \tilde{\mathbf{H}}_1^{T/2} (\hat{\mathbf{w}}_1 - \hat{\mathbf{w}}).$$

Из условий теоремы в силу теоремы 14 имеем

$$\tilde{\mathbf{H}}_1^{T/2} (\hat{\mathbf{w}}_1 - \hat{\mathbf{w}}) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{I}_n) \text{ при } m \rightarrow \infty$$

и в силу (4)

$$(\hat{\mathbf{w}}_2 - \hat{\mathbf{w}})^T \tilde{\mathbf{H}}_1^{1/2} \xrightarrow{\mathbb{P}} 0 \text{ при } m \rightarrow \infty$$

Отсюда из теоремы Слущкого имеем (6)

Таким образом, из (1), (2) и сходимости к нулю по вероятности первого (5) и последнего (6) слагаемых в (2) по теореме Слущкого в силу (3) для $k = 1$ получаем требуемое

$$-2 \log s - \text{score} = (\hat{\mathbf{w}}_2 - \hat{\mathbf{w}}_1)^T (\tilde{\mathbf{H}}_{m_1}^{-1}(\hat{\mathbf{w}}_1) + \tilde{\mathbf{H}}_{m_2}^{-1}(\hat{\mathbf{w}}_2))^{-1} (\hat{w}_2 - \hat{w}_1) \xrightarrow{d} \chi^2(n) \text{ при } m \rightarrow \infty.$$